

임동건

AI Engineer

대전, 대한민국 | gunni6112@gmail.com | 010-6886-7747
github.com/Whitejbb | LinkedIn | 개인 홈페이지

요약

처음 접하는 업무와 데이터를 빠르게 이해하고, **모호한 요구사항을 AI 시스템으로 구체화해 실제 운영 환경까지 연결하는 AI Engineer**입니다. Python/FastAPI 기반으로 사내 RAG, LangGraph Retrieval Agent, Browser AI System을 구축하며 **요구사항 분석 → 설계 → 구현 → 평가 → 배포·운영**까지 End-to-End로 경험했습니다. 검색 성능을 직접 평가하고 실패 사례와 평가 편향을 분석해 Retrieval 구조를 개선했으며, 온프레미스 LLM 서버·Fallback·무중단 재색인·백업/복구·CI/CD 등 **운영 환경의 제약과 장애 상황**을 고려한 시스템을 설계·구현했습니다.

핵심 역량

AI / Agent Systems RAG, LangGraph, Agent Workflow, Context Engineering, Agent Memory, Multi-Agent
Retrieval / Evaluation Qdrant, BGE-M3, Dense Search, BM25, RRF, Retrieval Evaluation
Backend / LLM Platform Python, FastAPI, PostgreSQL, Redis, vLLM, SSE, Model Routing, Failover
Platform / Application Docker, Nginx, Jenkins, GitLab, Nexus, SonarQube, React, TypeScript, MCP

경력

(주)엑스코어시스템

2026.03 - 2026.08

AI Engineer Intern

대한민국 세종특별자치시

사내 규정 검색 AI Assistant — 문서 탐색 문제를 온프레미스 AI 검색·운영 시스템으로 전환

- PDF 형태로 관리되던 사내 규정을 직원이 직접 찾아봐야 하는 문제를 분석하고, 문서 개정·재색인·복구 등 운영 요구까지 반영해 **자연어 검색부터 근거 확인·문서 운영까지 연결되는 온프레미스 AI 시스템으로 요구사항을 구체화**
- 요구사항 분석부터 데이터 구조, 문서 처리, Retrieval Pipeline, FastAPI Backend, 직원용 챗봇, 관리자 기능, 배포·운영 정책까지 **단독 설계·구현**
- PostgreSQL에는 문서 원문과 버전 이력을 저장하고, Qdrant는 재구축 가능한 검색 인덱스로 분리해 문서 구조 기반 청킹과 메타데이터를 반영한 임베딩, 답변 근거가 되는 문서·조항 출처 연결을 구현
- Dense·BM25·Hybrid 검색을 동일 평가셋에서 비교하고, Sparse 검색의 추가 기여 없이 순위가 하락하는 결과를 확인해 **복잡도를 늘리는 대신 Dense 기반 검색을 채택**
- 후속 질문을 독립 질의로 재작성하고, 모호한 질문에는 관련 문서·조항 후보를 제공하며 답변과 함께 출처를 반환하도록 실제 사용 흐름을 반영한 RAG 응답 Pipeline 설계
- 긴 문서와 표 정제 과정의 컨텍스트 길이 초과·출력 잘림·표 구조 변형에 대응해 분할 정제·실패 조각 재분할·표 구조 보존 로직 구현
- 질문 결과를 정상 답변·검색 근거 없음·출처 없음·오류로 구분하고, 출처·응답시간을 저장해 검색 실패와 답변 실패를 구분할 수 있는 운영 분석 데이터 구조 구성
- Qdrant Alias 기반 무중단 재색인과 PostgreSQL Dump·Qdrant Snapshot·Nexus 기반 백업/복구를 구성해 문서 개정과 장애 상황에서도 검색 인덱스를 안정적으로 재구축할 수 있는 운영 구조 구현
- 사내용 RAG 서비스를 고객사 환경에 설치할 수 있도록 Docker Compose·LLM Backend·인프라 연결·브랜딩 설정을 분리하고, Ed25519 라이선스 검증을 포함한 **배포 패키지를 단독 구성**
- 성과:** 55개 통제 질의 기반 평가에서 Dense Hit@8 98.2%, MRR@8 82.3% 기록, 외부 AI API 없이 온프레미스 환경에서 전체 추론 수행

사내 파일 탐색 AI Agent — 평가 편향을 발견하고 검색·Agent Workflow를 재설계

- 다양한 형식의 비정형 업무 문서를 파싱·청킹하고 파일명·경로·본문을 검색 가능한 데이터로 변환하는 Retrieval Agent를 **단독 설계·구현**
- LangGraph로 **의도 분석 → 메타데이터 검색 → 내용 검색 → 요약 → 응답** 5개 노드 Workflow를 구성하고, 내용 검색 단계에서 Dense·BM25 검색과 RRF 기반 결과 융합을 수행하며 단계별 실패 상황에 대한 대체 경로 구현
- 검색기별 점수 분포 차이를 RRF로 보정하고, 약한 파일명 검색 결과가 의미 검색 결과를 밀어내는 문제를 분석해 융합 전 품질 필터 적용
- 초기 평가에서 Vector·BM25·Agent 모두 Hit@5 100%가 나온 결과를 재검증해 **정답 파일명 단서로 인해 검색 성능이 과대평가되는 평가 편향을 발견**
- 유사 파일명 방해 문서와 패러프레이즈 질의를 추가해 240개 문서·106개 질의의 오프라인 평가 환경을 재구성하고, **Hybrid Hit@5 94.3%, MRR@5 80.9%**를 측정해 Vector 모드 대비 **Hit@5 +9.4%p, MRR@5 +6.8%p** 개선 확인
- Bootstrap 신뢰구간·paired permutation test·held-out 평가를 적용해 검색 방식 간 성능 차이가 우연인지 검토하고 평가 결과의 신뢰도를 함께 확인
- SHA-256으로 파일 변경 여부를 감지하고, UUID5를 적용해 동일 파일에 일관된 ID가 생성되도록 증분 인덱싱을 구성했으며, 스캔 경로 변경과 DB 반영 시점으로 발생한 **검색 결과 잔존·중복 임베딩 등 인덱스 정합성 문제를 수정**

온라인 경매 시스템 · ERP 연계 데이터 모델 설계 — Prototype부터 실제 구현·데이터 설계까지 현업 요구를 서비스 구조로 구체화

- 초기 요구사항이 구체화되지 않은 상태에서 업무 담당자와의 회의에 활용할 **React 기반 Prototype**을 구현하고, 피드백을 통해 기능과 화면 흐름을 구체화한 뒤 Java 기반 재구현 및 실제 프로젝트 코드베이스 이식까지 수행
- 외부 ERP의 품목·상장·낙찰 인터페이스와 Excel 원천 정의를 분석하고, 내부 경매 시스템에 필요한 식별키·키 관계·상태·관리 컬럼을 포함한 관계형 데이터 모델을 팀원과 함께 설계
- 품목 분류체계와 상장·낙찰 데이터 관계를 분석하고 자기참조·참조 무결성·Join 시나리오를 검토해 서비스 데이터 흐름에 맞는 구조 설계
- 인터페이스 매핑·테이블 정의서·ERD·Decision Log를 문서화하고, 설계 원본에서 Excel 정의서와 ERD를 생성·검증하는 Python 도구 구성

사내망 CI/CD 개발환경 구축 — 폐쇄망 환경까지 고려한 사내 빌드·배포 환경 표준화

- 프로젝트마다 달랐던 빌드·배포 절차를 분석해 GitLab → Jenkins → SonarQube/Nexus → Application으로 이어지는 **사내 CI/CD Pipeline**을 **단독 구축**
- 폐쇄망 환경에서도 재현 가능한 빌드·배포를 고려해 내부 저장소 기반 의존성 관리 구조를 구성하고, Java 버전·권한·SELinux·네트워크 등 구축 과정의 장애를 분석·해결
- 신규 VM에서도 동일 환경을 재구축할 수 있도록 설치·운영·백업·장애 대응 절차를 문서화

Orbit — Personal Exploration Memory / AI Browser Agent

2026

브라우저 방문 이벤트를 탐색 의도 중심 세션으로 자동 구성하고 이전 탐색 맥락을 검색·복원하는 Browser AI System

2026 AI Rookie Competition 국내 AI 트랙 결선 진출 · React · TypeScript · Chrome MV3 · FastAPI · PostgreSQL · Redis · Qdrant

- Chrome Extension의 webNavigation 기반 방문 이벤트를 opt-in으로 수집하고 IndexedDB 로컬 큐에 저장한 뒤, 수동·주기·개수·유류 조건에서 Batch Sync하는 이벤트 수집 구조 구현
- 새 이벤트의 의도와 기존 Session Context를 비교해 **append · create · hold · discard**를 판단하는 Auto Session Pipeline을 설계하고, 서로 다른 탐색 맥락이 섞이지 않도록 Session Memory 구성
- 세션의 목적·핵심 내용·미완료 작업·다음 행동을 구조화하고, 과거 탐색 기록을 단순 키워드가 아닌 **사용자 의도 기반으로 검색·복원**하는 기능 구현
- Search by Intent · Ask AI · 열린 탭 의미 검색 · 이동 · 세션 병합 · Exploration Timeline 등 저장된 탐색 Context를 **검색·탭 이동·세션 복원 등 브라우저 내 실제 탐색 행동으로 다시 연결**하는 사용자 흐름 구현
- Golden Set 기반 평가 Harness를 구축하고 세션 할당 정확도 · 순도 · 커버리지 · 신규 세션 판별 · 노이즈 제외율을 측정해 Auto Session 판단 품질을 반복 검증
- K-EXAONE을 세션 의도 분석 Primary, A.X-K1을 요약·답변·리랭킹 중심으로 역할 분담하고 Upstage Embedding과 단계별 상호 Fallback을 적용
- Provider별 호출 제약과 응답 특성을 비교해 의도 분석·요약·검색 단계별 모델을 다르게 배치하고, 특정 모델 API에 장애가 발생해도 주요 기능을 유지하도록 AI Pipeline 구성

화백 — Multi-Agent Decision Runtime

2026

여러 LLM Agent가 직접 메시지를 교환하고 제안·검토·투표를 거쳐 합의안을 만드는 Multi-Agent Orchestration Runtime

개인 프로젝트 · Python · asyncio · FastAPI · SSE · SQLite · Next.js

- LangGraph·CrewAI 같은 Agent Framework 없이 async 기반 Message Bus·Agent Tool Loop·Consensus Engine을 직접 구현해 **멀티에이전트 Runtime의 핵심 실행 구조를 설계**
- Agent가 중앙 조율자 없이 직접 메시지를 교환하도록 구성하고, 제안·투표·수정안 제출·합의 판정을 별도 Consensus Engine으로 분리
- discussion → synthesis → proposal → voting → revision의 단계별 실행 흐름과 전이 규칙을 설계하고, **각 단계에서 사용할 수 있는 Tool을 제한**해 무한 대화와 비수렴을 Runtime 수준에서 제어
- 동시 Agent 호출에서 여러 요청이 동시에 토큰 예산을 사용해 전체 한도를 초과하는 문제를 막기 위해 **호출 전에 예상 토큰 예산을 선점**하도록 구성하고, 메시지 수·턴 수·제안 버전·Timeout에 각각 실행 상한 적용
- REST/SSE 기반 이벤트 스트림과 SQLite 영속화를 구성하고, SSE 재연결 시 **Last-Event-ID를 기준으로 누락 이벤트를 복구**해 Agent 상태·메시지·제안·투표·예산 흐름을 실시간 추적
- **검증**: Runtime 6.7k LOC, 테스트 513개를 구성하고 Timeout·예산 초과·취소·투표 만료 등 실패 경로까지 자동 검증

Forge — Task-aware LLM Gateway

2026

코딩 Agent의 작업 특성과 Provider 상태·비용에 따라 모델을 선택하고 장애 시 자동 전환하는 Local AI Gateway

개인 프로젝트 · PyPI v0.4.0 · Python · FastAPI · LiteLLM · Prometheus · SQLite

- Claude Code·Cline·Aider·Continue 등이 하나의 Endpoint를 통해 여러 LLM Provider를 사용할 수 있도록 **OpenAI·Anthropic 호환 API Gateway** 구현
- 요청을 coding·debugging·refactoring·documentation·testing 등으로 분류하고, Tool Use·Vision·JSON Mode·Context Window 등 **작업에 필요한 기능을 지원하는 모델만 후보로 선별**
- 후보 모델의 성능·상태·지연시간·가용성·비용을 점수화해 Task-aware Routing을 수행하고, **대화 중에는 가능한 동일 모델을 유지해 세션 일관성을 확보**
- 429·5xx·Timeout·Context Overflow 발생 시 Streaming Failover·Multi-Key Rotation·API Key별 Cooldown을 적용해 장애 전환 자동화
- 요청별 비용 상한·무료/로컬 모델 우선 정책·Hot Reload·Prometheus/SQLite Metrics·Dashboard를 구성하고 Route Explain API로 모델 제외·선택 이유를 확인 가능하게 구현
- 실제 요청의 성공·실패 데이터를 Capability Score에 반영해 모델별 기능 신뢰도를 동적으로 보정하는 Model Learning 구조를 적용하고, **16개 Provider를 지원하는 PyPI v0.4.0 패키지로 배포**

추가 프로젝트

- **Devtrail — Engineering Memory**: AI Coding 세션의 작업 배경·설계 결정·문제·인수인계 정보를 Obsidian에 축적하고, MCP를 통해 다음 Agent가 프로젝트 맥락과 최근 작업을 이어받도록 구현. 수집 → 정제 → 검토 → 승격 Pipeline, Shell Activity 수집, nightly/weekly 자동 정제와 Human Review 구조를 구성해 AI 개발 세션 간 Context를 이어가는 Engineering Memory System으로 확장
- **Docker-based Federated Learning Testbed**: Docker 기반 시스템 이질성 환경에서 BWA·ADM 알고리즘을 구현하고, BWA 정확도 +2.70%p 및 ADM 학습시간 -21.3%를 실험으로 검증 (제1저자)
- **AfterFail — Kubernetes 장애 대응 훈련 플랫폼**: Chaos Mesh 장애 시나리오, 웹 터미널, Prometheus·Grafana와 RAG 기반 AI Tutor를 결합한 교육 플랫폼을 프로젝트 총괄 및 프론트엔드 담당으로 개발

학력 및 연구

국립한밭대학교 컴퓨터공학과

2021.03 – 2027.02 졸업 예정

학사 재학 중 · ICIS Lab 학부연구생 (2025.03 – 2026.04)

대전

이질적 연합학습을 위한 도커 기반 테스트베드 구축 및 BWA·ADM 기법 성능 검증

임동건 외 2명 · 한국통신학회 동계종합학술대회, 제1저자 · 2026

쿠버네티스 기반 연합학습 및 스플릿 컴퓨팅의 최신 연구 동향

임동건 외 4명 · 한국통신학회 추계종합학술대회, 제1저자 · 2025

활동 · 수상 · 자격

활동 ; 낭만인프라 클라우드 인프라 스터디 DevOps 담당 · 공통 CI/CD 환경 구축 · KREONET 오픈소스 워킹그룹 발표

수상 ; 소중한 오픈소스 활용 SW 경진대회 1등 · 총장상 | CEDC 2025 Bronze Award | KRAFTON Jungle 웹개발 집중 캠프 3기 우수 수료

자격 ; NCP Professional | AWS Certified Cloud Practitioner | NCP Associate | 정보처리기능사 | TOEIC 860