

임동건

AI Agent Engineer / LLM Systems Engineer

대전, 대한민국 | gunni6112@gmail.com | 010-6886-7747

github.com/WhiteJbb | LinkedIn

요약

Python/FastAPI 기반의 LLM 시스템을 요구사항 분석부터 Agent Workflow 설계, RAG, 온프레미스 LLM 서버, 배포 및 운영까지 End-to-End 로 구축했습니다. LangGraph 기반 Retrieval Agent와 Browser Context Agent를 개발하며 의도 분석, 검색 라우팅, Memory, 실패 단계별 Fallback 구조를 구현했습니다. 실제 사용자 질의를 평가셋으로 구성해 검색 품질을 정량 검증하고, 무중단 재색인·백업/복구·Failover·운영 지표 수집 등 반복 가능한 운영 시스템을 만드는 데 강점이 있습니다.

핵심 역량

AI Agent Systems LangGraph, Agent Workflow, RAG, Agent Memory, Browser Context

LLM Systems vLLM, BGE-M3, Qdrant, Hybrid Search, Retrieval Evaluation, Model Routing, Failover

Backend Python, FastAPI, PostgreSQL, Redis, REST API, SSE

Automation / Integration Chrome Extension MV3, MCP, Workflow Automation, ERP Data Modeling

Infrastructure Docker, Docker Compose, Jenkins, GitLab, Harbor, Nexus, SonarQube, Prometheus

Frontend React, TypeScript

경력

(주)엑스코어시스템

2026.03 – 2026.08 예정

AI Engineer Intern

대한민국

사내 규정 검색 AI Assistant — 약 60명 규모 조직을 위한 온프레미스 RAG 챗봇·문서 운영 플랫폼

- 이미지 PDF와 공유폴더 중심으로 관리되던 사내 규정을 자연어로 검색할 수 있도록 요구사항 분석부터 데이터 구조, 검색 파이프라인, API, 관리자 기능, 배포 및 운영 정책까지 단독 설계·구현
- PostgreSQL을 문서 원문·버전 이력의 기준 저장소로, Qdrant를 재구축 가능한 검색 인덱스로 분리하고 문서 구조 기반 청킹·메타데이터 결합 임베딩·필드별 키워드 재정렬을 적용해 검색 정확도 개선
- 대화 문맥을 반영해 후속 질문을 독립 질의로 재작성하고, 모호한 질의에는 관련 문서·조항 선택지를 제공하며 답변과 함께 근거 문서 및 조항을 반환하도록 RAG 응답 흐름 설계
- Qdrant Alias 전환 기반 무중단 재색인과 PostgreSQL Dump·Qdrant Snapshot·Nexus를 활용한 백업/복구 파이프라인을 구축해 운영 중 문서 갱신과 장애 복구 절차 표준화
- 성과:** 55개 실사용 질의 기반 내부 벤치마크에서 Hit@8 98.2%, MRR@8 82.3%를 기록하고, 외부 AI API 없이 온프레미스 환경에서 전체 추론 수행
- 기술:** Python, FastAPI, React, PostgreSQL, Qdrant, vLLM, BGE-M3, SSE, Docker, Nexus

사내 파일 탐색 AI Agent — 공유폴더의 비정형 업무 문서를 자연어로 검색하는 LangGraph 기반 Retrieval Agent

- PDF, DOCX, PPTX, XLSX, HWP, 이미지 등 13개 확장자를 파싱·청킹하고 Dense Search, BM25, 파일명 메타데이터 검색을 결합한 파일 검색 시스템 개발
- LangGraph로 의도 분석 → 메타데이터 검색 → 내용 검색 → 결과 융합 → 요약 → 응답 Workflow를 구성하고, 검색 결과 부족·파싱 실패 등 단계별 예외 상황에 대한 Fallback 경로 구현
- 검색 방식별 점수 분포 차이를 RRF로 보정하고, 신뢰도가 낮은 파일명 매치를 결과 융합 전에 제외해 의미 검색 결과가 밀려나는 문제를 해결했으며 개선 효과 **+40.2%p** 검증
- 파일명 편향으로 모든 방식이 동일하게 100%를 기록하는 평가 오류를 발견하고, 유사 파일명 방해 문서와 패러프레이즈 질의를 포함한 240개 문서·106개 질의 평가셋을 재구축해 Hit@5 94.3%, MRR@5 80.9% 측정
- SHA-256 기반 변경 감지와 UUID5 기반 고정 ID 생성을 적용해 변경된 파일만 재처리하고 재실행 시 중복 인덱싱 방지
- 기술:** Python, FastAPI, LangGraph, Qdrant, PostgreSQL, BGE-M3, BM25, RRF, Kiwi, vLLM, Docker

온라인 경매 ERP 연계 데이터 모델 설계 — 외부 ERP 연계 요구사항을 내부 경매 시스템의 실행 가능한 DB 구조로 전환

- 외부 ERP에서 전달된 품목·상장·낙찰 인터페이스와 필수 연계 항목을 분석하고, 내부 온라인 경매 서비스에서 필요한 식별키·PK/FK·상태 및 관리 컬럼을 포함해 테이블 구조 재설계
- 품목 분류체계와 상장·낙찰 데이터의 관계를 정리하고 자기참조·참조 무결성·조인 시나리오를 검토해 실제 운영 데이터 흐름에 맞는 관계형 모델 설계
- Excel 원천 정의서 분석, Interface Mapping, ERD/Relationship, Decision Log 문서화를 병행하고 개발 DB에 신규 테이블 및 사용자 관련 컬럼 반영

사내망 CI/CD 개발환경 구축 — 형상관리부터 분석·빌드·배포까지 연결되는 내부 개발환경

- GitLab, Jenkins, SonarQube, Nexus를 연동해 사내망 환경에서 형상관리, 정적 분석, 빌드 및 배포를 자동화하는 CI/CD 파이프라인 구축
- 외부 네트워크 접근 없이도 재현 가능한 내부 저장소 기반 빌드 환경을 구성하고 설치 절차·환경 설정·장애 해결 방법을 문서화

Orbit — AI Browser Agent

2026

브라우저의 탭·페이지·탐색 세션을 수집하고 사용자의 목적 중심으로 분류·요약해 탐색 맥락을 유지·복원하는 Browser Agent
AI Rookie Competition 예선 통과 · React · TypeScript · Chrome MV3 · FastAPI · PostgreSQL · Redis · Qdrant

- Chrome Extension의 Service Worker와 Content Script를 분리해 탭 상태·방문 이벤트·페이지 컨텍스트를 수집하고 서버의 세션 파이프라인과 연결
- 새 탐색 기록과 기존 세션의 관계를 분석해 세션 생성·추가·보류·제외를 판단하고, 주제별 탐색 맥락을 분리해 사용자가 진행 중인 웹 작업의 Context를 유지하도록 설계
- 세션별 목적·핵심 내용·미완료 작업·다음 행동을 구조화해 Memory로 저장하고, 이전 탐색 흐름을 자연어로 다시 찾을 수 있도록 검색·복원 기능 구현
- 브라우저 상태 수집, 의도 분석, Session Memory, RAG를 독립된 Pipeline으로 구성해 기능 변경과 Agent 확장이 가능한 구조로 설계

Forge — Task-aware LLM Gateway

2026

코딩 에이전트 요청의 작업 유형과 실행 상태를 분석해 적합한 LLM으로 라우팅하는 로컬 AI Gateway

개인 프로젝트 · Python · FastAPI · LiteLLM · Prometheus · SQLite

- Claude Code, Cline, Aider 등이 클라이언트 설정 변경 없이 여러 LLM Provider를 사용할 수 있도록 단일 Gateway Endpoint 구현
- 작업 유형과 Tool Use, Vision, JSON Mode, Context Window 요구사항을 분석하고 모델 성능·성공률·지연시간·가용성·비용을 점수화해 후보 모델 선택
- 429·5xx·Timeout·Context Overflow 발생 시 다음 후보로 전환하는 스트리밍 Failover와 다중 API Key 순환 구조 구현
- 요청별 비용 상한, 무료 모델 우선 정책, 세션별 모델 유지, 설정 Hot Reload 및 Prometheus 기반 운영 지표 수집 기능 구현

Devtrail — Agent Memory & Knowledge OS

2026

AI 개발 도구의 작업 기록과 의사결정을 세션 간 지속 가능한 프로젝트 지식으로 전환하는 Agent Memory Platform

개인 프로젝트 · Python · MCP · Obsidian · Telegram · LLM API

- 세션 종료·Context 압축 시 작업 배경과 판단 근거가 유실되는 문제를 해결하기 위해 Obsidian Vault 기반 Capture → Distill → Review → Promote 지식 파이프라인 구현
- MCP 서버를 통해 세션 시작 시 프로젝트 배경·최근 작업·미해결 항목을 제공하고, 종료 전 변경 사항·판단 근거·다음 할 일을 기록하는 세션 간 Handoff 구조 구현
- 작업 유형에 따라 Gemini, OpenAI, Kimi, Ollama, vLLM을 선택하고 호출 실패 시 다음 Provider로 전환하는 LLM Routing 및 Fallback 구현

추가 프로젝트

- **화백 — Multi-Agent Decision System:** 역할별 LLM Agent가 비동기 Message Bus에서 독립 검토·토론·투표·수정을 수행하는 Multi-Agent Runtime과 실시간 상태·토큰 관측 대시보드 구현
- **Docker-based Federated Learning Testbed:** Docker 기반 시스템 이질성 환경에서 BWA·ADM 알고리즘을 구현하고, BWA 정확도 +2.70%p 및 ADM 학습시간 -21.3% 검증 (제1저자)
- **AfterFail — Kubernetes 장애 대응 훈련 플랫폼:** Chaos Mesh, 웹 터미널, Prometheus·Grafana와 RAG 기반 AI Tutor를 결합한 플랫폼을 프로젝트 총괄 및 프론트엔드 담당으로 개발

학력 및 연구

국립한밭대학교 컴퓨터공학과

2021.03 – 현재

학사 재학 중 · ICIS Lab 학부연구생 (2025.03 – 2026.04)

대전

이질적 연합학습을 위한 도커 기반 테스트베드 구축 및 BWA·ADM 기법 성능 검증

임동건 외 2명 · 한국통신학회 동계종합학술대회, 제1저자 · 2026

쿠버네티스 기반 연합학습 및 스플릿 컴퓨팅의 최신 연구 동향

임동건 외 4명 · 한국통신학회 추계종합학술대회, 제1저자 · 2025

활동 및 수상

- **낭만인프라 클라우드 인프라 스터디 · DevOps 담당:** 11인 스터디의 웹 프로젝트를 대상으로 Jenkins, Harbor, SonarQube, Watchtower 기반 공통 CI/CD 환경 설계·구축 및 KREONET 오픈소스 워킹그룹 발표
- **소중한 오픈소스 활용 SW 경진대회 · 1등 및 총장상**
- **CEDC 2025 · Bronze Award**
- **KRAFTON Jungle 웹개발 집중캠프 3기 · 우수 수료생**

자격 및 어학

NAVER Cloud Platform Certified Professional | AWS Certified Cloud Practitioner

NAVER Cloud Platform Certified Associate | 정보처리기사 | TOEIC 860